搜索引擎项目

要求：必须使用 CMake 来管理项目！

1. 第一期 离线部分

1.1 1.1 关键字推荐

1.1.1 需求

根据语料库和停用词生成 **词典库** 和 **索引库**。

英文：

- 打开目录，读取语料文件 (目录流：`opendir()`, `closedir()`, `readdir()`)。
- 分词：去掉数字和标点符号，只保留字母；将字母统一转换成小写；按空白字符分割。
- 过滤掉停用词。
- 统计每一个单词 (Token) 的出现的频率。
- 生成词典库和索引库。

dict_en.dat

```
 1 aah 1
 2 aaron 355
 3 aaronites 2
 4 ab 2
 5 aback 3
 6 abacus 1
 7 abaddon 1
 8 abagtha 1
 9 abana 1
10 abandon 32
11 abandoned 72
12 abandoning 27
13 abandonment 15
14 abandons 2
15 abarim 4
```

index_en.dat

```
 1 a 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23
 2 b 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18 19 20 21 22 23 24 25
 3 c 5 6 31 35 36 42 43 44 45 46 47 51 58 62 93 105 106 154 155 1
 4 d 7 10 11 12 13 14 17 19 22 32 33 34 35 36 37 38 39 40 41 42 4
 5 e 3 11 13 16 17 18 19 21 22 23 25 26 30 33 35 36 37 38 39 43 4
 6 f 553 627 628 629 630 631 632 633 634 635 636 637 638 639 640
 7 g 8 12 20 44 49 66 78 83 97 112 123 137 146 147 148 150 170 17
 8 h 1 8 19 51 53 55 60 61 62 63 64 65 66 69 71 72 77 84 85 86 87
 9 i 3 12 15 20 30 34 35 36 37 40 44 45 52 54 55 66 67 68 69 70 7
10 j 87 88 105 106 107 455 456 457 458 459 460 461 462 463 464 46
11 k 5 320 321 322 323 324 325 326 520 522 524 544 794 859 860 86
12 l 33 37 40 50 51 52 53 54 55 70 79 83 84 89 90 91 92 93 99 102
13 m 13 15 18 23 38 39 40 51 52 53 54 55 88 92 93 95 96 99 114 11
14 n 2 3 7 9 10 11 12 13 14 18 20 23 30 38 39 40 41 44 45 49 56 5
15 o 2 3 7 10 11 12 13 14 27 28 29 30 38 39 40 41 45 46 47 49 53
```

中文：

- 打开目录，读取语料文件 (目录流：`opendir()`, `closedir()`, `readdir()`)。
- 使用 cppjieba 分词。
- 过滤掉停用词。
- 统计每一个单词 (Token) 的出现的频率。
- 生成词典库和索引库 (需要使用 utfcpp 库分割出一个一个汉字)。

dict_cn.dat

```
一一 1
一万年 1
一下 13
一下子 2
一世 2
一丝 2
一个 280
一个个 1
一举 1
一九二七年 1
一书 1
一五 1
一些 72
一人 1
一代 5
```

index_cn.dat

```
一 1 2 3 4 5 6 7 8 9 10 11 12 13 14 15 16 17 18
丁 209 210 211 1603 2085 6977 8301 16774
七 10 212 213 214 215 216 217 218 219 220 221 2
万 2 228 229 230 231 232 233 234 235 236 237 23
丈 229 250 5445
三 251 252 253 254 255 256 257 258 259 260 261
上 325 326 327 328 329 330 331 332 333 334 335
下 3 4 154 366 367 368 369 370 371 372 373 374
不 178 298 367 393 394 395 396 397 398 399 400
与 649 650 651 652 653 654 655 656 657 658 659
丑 663 664 665 666 2710 5752 6155 13375
专 667 668 669 670 671 672 673 674 675 676 677
且 692 693 842 6625 9497
世 5 694 695 696 697 698 699 700 701 702 703 70
丘 722 10528 12912
```

1.1.2 设计

```cpp
// DirectoryScanner.h
#pragma once
#include <vector>
#include <string>

class DirectoryScanner
{
public:
    /**
     * 遍历目录 dir, 获取目录里面的所有文件名
     */
    static std::vector<std::string> scan(const std::string& dir);

```

```
private:
    DirectoryScanner() = delete;
};
```

```
// KeywordProcessor.h
#pragma once
#include <cppjieba/Jieba.hpp>
#include <string>
#include <set>

class KeyWordProcessor {
public:
    KeyWordProcessor();

    // chDir: 中文语料库
    // enDir: 英文语料库
    void process(const std::string& chDir, const std::string& enDir);

private:
    void create_cn_dict(const std::string& dir, const std::string& outfile);
    void build_cn_index(const std::string& dict, const std::string& index);

    void create_en_dict(const std::string& dir, const std::string& outfile);
    void build_en_index(const std::string& dict, const std::string& index);
private:
    cppjieba::Jieba m_tokenizer;
    std::set<std::string> m_enStopWords;
    std::set<std::string> m_chStopWords;
};
```

1.1.3 cppjieba 库

安装

cppjieba 是一个 header-only 的库，我们需要将对应的文件放到 `/usr/local/include` 目录下，然后在将 `dict` 目录移动到 `/usr/local` 目录下：

```
he@he-vm:~$ tree /usr/local/include/cppjieba/
/usr/local/include/cppjieba/
├── DictTrie.hpp
├── FullSegment.hpp
├── HMMModel.hpp
├── HMMSegment.hpp
├── Jieba.hpp
├── KeywordExtractor.hpp
├── limonp
│   ├── ArgvContext.hpp
│   ├── Closure.hpp
│   ├── Colors.hpp
│   ├── Condition.hpp
│   ├── Config.hpp
│   ├── ForcePublic.hpp
│   ├── LocalVector.hpp
│   ├── Logging.hpp
│   ├── NonCopyable.hpp
│   ├── StdExtension.hpp
│   └── StringUtil.hpp
├── MixSegment.hpp
├── MPSegment.hpp
├── PosTagger.hpp
├── PreFilter.hpp
├── QuerySegment.hpp
├── SegmentBase.hpp
├── SegmentTagged.hpp
├── TextRankExtractor.hpp
├── Trie.hpp
└── Unicode.hpp
```

```
he@he-vm:~$ tree /usr/local/dict/
/usr/local/dict/
├── hmm_model.utf8
├── idf.utf8
├── jieba.dict.utf8
├── pos_dict
│   ├── char_state_tab.utf8
│   ├── prob_emit.utf8
│   ├── prob_start.utf8
│   └── prob_trans.utf8
├── README.md
├── stop_words.utf8
└── user.dict.utf8
```

使用

cppjieba 有多种分词方式，其中最重要的有三种方式：MP (Maximum Probability 最大概率分词)，HMM (Hidden Markov Model 隐马模型分词)，Mix (混合模式：默认方式)。它们的区别如下：

模式	方法	特性
MP	`Cut(sentence, words, false)`	基于前缀词典构建词图，使用动态规划找最大概率路径 (精确分词)
HMM	`CutHMM(sentence, words)`	基于隐马模型，适合新词识别
Mix	`Cut(sentence, words)`	先 MP 分词，再用 HMM 识别 MP 无法识别的新词

接下来，我们写一个的示例，演示一下这三种分词方法的区别：

```cpp
// exampe01.cc
#include <iostream>
#include "cppjieba/Jieba.hpp"

void print_words(const std::string& title, const std::vector<std::string>& words)
{
    std::cout << "[" << title << "] ";
    for (const auto& w : words) {
        std::cout << w << "/ ";
    }
    std::cout << std::endl;
}

int main()
{
    // 创建Jieba对象会读取配置文件，所以比较耗时
    // 最佳实践: 最好只创建一个Jieba对象
    cppjieba::Jieba tokenizer;

    std::string s = "金胖胖是一名杰出的计算机科学家，他来到了今天武汉天源迪科，让我们热烈欢迎金胖胖同学！";
    std::vector<std::string> words;

    // [MP]
    tokenizer.Cut(s, words, false); // HMM = false
    print_words("MP", words);

    // [HMM]
    tokenizer.CutHMM(s, words);
    print_words("HMM", words);

    // [MIX]
    // tokenizer.Cut(s, words, true);  // HMM = true
    tokenizer.Cut(s, words);
    print_words("MIX", words);
}
```

1.1.4 utfcpp 库

安装

utfcpp 也是一个 header-only 的库，我们只需要将对应的文件放到 `/usr/local/include` 目录下即可：

```
he@he-vm:~$ tree /usr/local/include/utfcpp/
/usr/local/include/utfcpp/
├── utf8
│   ├── checked.h
│   ├── core.h
│   ├── cpp11.h
│   ├── cpp17.h
│   ├── cpp20.h
│   └── unchecked.h
└── utf8.h
```

使用

```cpp
// example01.cc
//   打印每一个汉字的Unicode码点(Unicode codepoint)
#include <iostream>
#include "utfcpp/utf8.h"

int main()
{
    std::string s = "你好，世界！!";

    auto it = utf8::iterator{ s.begin(), s.begin(), s.end() };
    auto end = utf8::iterator{ s.end(), s.begin(), s.end()  };

    for (; it != end; ++it) {
        char32_t codepoint = *it;
        std::cout << "U+" << std::hex << codepoint << "\n";
    }
}
```

```cpp
// example02.cc
//   打印一个一个汉字
#include <iostream>
#include "utfcpp/utf8.h"

int main()
{
    std::string s = "你好，世界！!";

    const char* it = s.c_str();
    const char* end = s.c_str() + s.size();

    while (it != end) {
        auto start = it;
        utf8::next(it, end);    // 将it移动到下一个utf8字符所在的位置
```

```
            // 因为一个汉字需要占用多个字节,我们可以用std::string来表示一个汉字
            std::string alpha = std::string{ start, it };
            std::cout << alpha << "\n";
        }
    }
```

1.2 1.2 网页搜索

1.2.1 需求

我们要根据给定的语料 (在公司中，往往是爬取下来的网页，或者是公司内部的文档)，生成 **网页库**、**网页偏移库** 和 **倒排索引库**。

网页库 的格式如下所示：包含 < doc >, < id >, < link >, < title >, < content > 等标签。

```
<doc>
  <id>1</id>
  <link>http://scitech.people.com.cn/n1/2021/0217/c1007-32030067.html</link>
  <title>中国空间站首批航天员乘组正着重开展出舱活动等训练</title>
  <content>      中新社北京2月16日电 (郭超凯)记者16日从中国载人航天工程办公室获
</doc>
<doc>
  <id>2</id>
  <link>http://scitech.people.com.cn/n1/2021/0212/c1007-32028847.html</link>
  <title>天问一号“奔火”“太空刹车”成功</title>
  <content>    2月10日19时52分，中国首次火星探测任务“天问一号”探测器实施捕获制
</doc>
<doc>
  <id>3</id>
  <link>http://scitech.people.com.cn/n1/2021/0211/c1007-32028637.html</link>
  <title>中国科研团队发布量子计算机操作系统</title>
  <content>    据新华社电　（记者徐海涛）操作系统是管理计算机软硬件的“大管家”,
</doc>
```

网页偏移库 的目的是 **快速地定位文档**，它个格式是: < 文档 id > < 偏移量 > < 文档大小 >

```
1 1 0 2681
2 2 2681 2749
3 3 5430 1921
4 4 7351 2440
5 5 9791 7166
6 6 16957 1558
7 7 18515 1149
8 8 19664 1149
9 9 20813 1141
10 10 21954 1150
11 11 23104 1150
12 12 24254 1150
13 13 25404 1150
14 14 26554 1150
15 15 27704 1150
```

倒排索引库 是搜索引擎很核心的一个数据结构，它的格式如下：< 关键字 > < 文档 id > < 关键字在文档中的权重 > [< 文档 id > < 关键字在文档中的权重 >]...

```
一一 23 0.0202283 49 0.0136804 62 0.0196741 1280 0.0359543 1287 0.0485953
一一列举 2198 0.025631
一一对应 1921 0.0170253 3333 0.00885305
一万 1122 0.0654998 1320 0.0194682 1470 0.0192643 4304 0.032548
一万个 1630 0.024991 2647 0.023272
一万亿 47 0.0525517
一万亿美元 2922 0.0195681
一万八千 1770 0.0591041
一万名 3798 0.0573116 3938 0.0950532
一万块 4017 0.0422778
一万多 1819 0.0779154
一万多个 3525 0.047755
一万多名 1231 0.012096
一万头 279 0.0136218
一万年 502 0.0465448 1686 0.0154775
```

1.2.2 流程

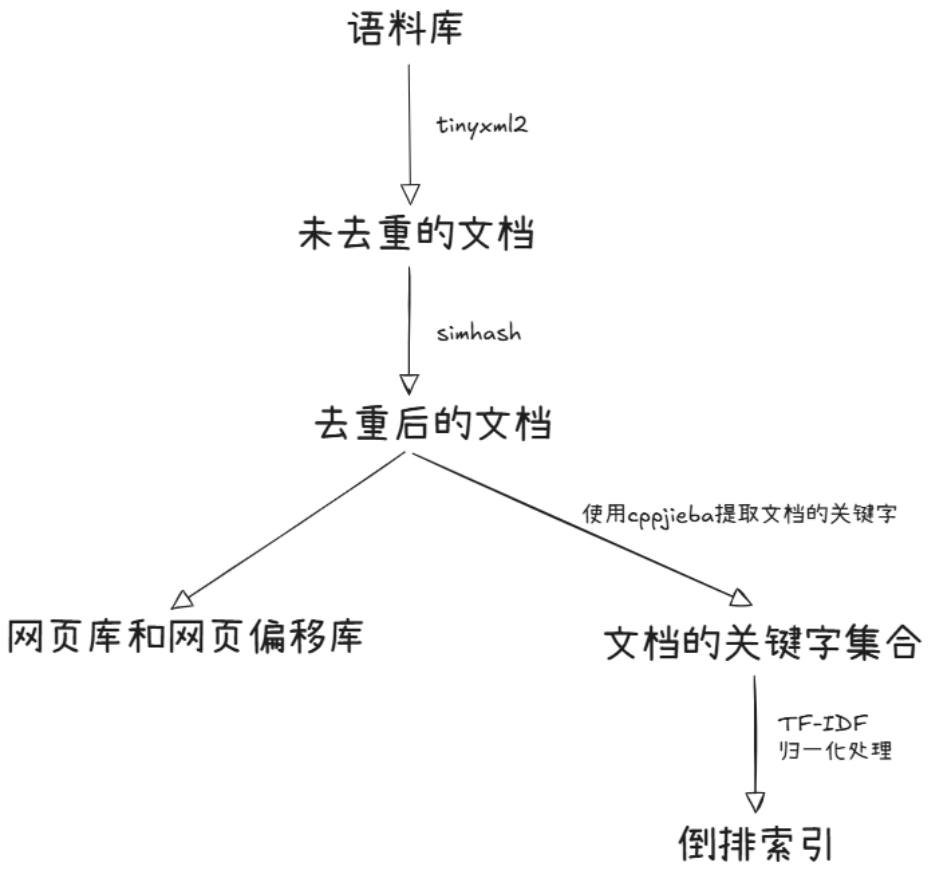

- 使用 `tinyxml2` 提取语料库中的文档
  - 我们要为 xml 文件中每一个 < item > 标签生成一个 < doc >
  - 如果 < item > 中有 < content >，将 < content > 标签中的内容作为 < doc > 的 < content > 的内容；如果 < item > 中没有 < content > 标签，那么将 < description > 标签中的内容作为 < doc > 的 < content > 内容；如果 < item > 中也没有 < description > 标签，那么忽略该 < item >。

- 使用 `simhash` 库对文档去重。
    - 计算每篇文档的 `simhash` 值，根据汉明距离对文档去重 (我们认为汉明距离在 3 以内的文档，内容是十分相似的)。
- 根据去重后的文档，生成网页库和网页偏移库。
- 使用 cppjieba 提取去重后文档中的关键字。
- 使用 `TF-IDF` 算法计算关键字在文档中的权重，对关键字的权重进行归一化处理。
- 生成倒排索引库。

1.2.3 设计

```cpp
// DirectoryScanner.h
#pragma once
#include <vector>
#include <string>

class DirectoryScanner
{
public:
    static std::vector<std::string> scan(const std::string& dir);

private:
    DirectoryScanner() = delete;
};
```

```cpp
// PageProcessor.h
#pragma once
#include <string>
#include <vector>
#include <set>

#include "cppjieba/Jieba.hpp"
#include "simhash/Simhasher.hpp"

class PageProcessor
{
public:
    PageProcessor();
    void process(const std::string& dir);

private:
    void extract_documents(const std::string& dir);
    void deduplicate_documents();
    void build_pages_and_offsets(const std::string& pages, const std::string&
offsets);
    void build_inverted_index(const std::string& filename);
private:
    struct Document
    {
        int id;
        std::string link;
```

```
        std::string title;
        std::string content;
    };

private:
    cppjieba::Jieba m_tokenizer;
    simhash::Simhasher m_hasher;
    std::set<std::string> m_stopWords;    // 使用set，而非vector，是为了方便查找
    std::vector<Document> m_documents;
    std::map<std::string, std::map<int, double>> m_invertedIndex;
};
```

1.2.4 simhash 库

安装

simhash 库和 cppjieba 库是同一个作者写的，我们只需要将对应的头文件拷贝到 `/usr/local/include` 目录下即可。

```
he@he-vm:~$ tree /usr/local/include/simhash/
/usr/local/include/simhash/
├── jenkins.h
└── Simhasher.hpp
```

示例

```
/**
 * example01.cc
 *   提取特征，生成simhash值
 */
#include <iostream>
#include <fstream>
#include "simhash/Simhasher.hpp"

using namespace simhash;

int main(int argc, char** argv)
{
    Simhasher simhasher;
    string content = "我是蓝翔技工拖拉机学院手扶拖拉机专业的。不用多久，我就会升职加薪，当上总经理，出任CEO，走上人生巅峰。";

    // 提取特征
    size_t topN = 5;
    vector<pair<string ,double>> features;
    simhasher.extract(content, features, topN);
    for (const auto& [feature, weight] : features) {
        cout << feature << ": " << weight << "\n";
    }

    // 生成simhash值
    uint64_t hashcode;
    simhasher.make(content, topN, hashcode);
```

```
27      cout<< "simhash值是: " << hashcode <<endl;
28      string s;
29      Simhasher::toBinaryString(hashcode, s);
30      cout << "二进制序列: " << s << "\n";
31  }
```

1.2.5 TF-IDF 算法

该算法会涉及到如下几个概念：

TF (Term Frequency): 词语在文档中出现的频率。

DF (Document Frequency): 包含词语的文档个数。

IDF (Inverse Document Frequency)：逆文档频率，其计算公式为 $\mathrm{IDF} = log_2(\mathrm{N}/\mathrm{DF})$，其中 N 表示文档的总数。

理解这些概念之后，我们就可以计算关键字的 TF-IDF 权重了：$w = \mathrm{TF} * \mathrm{IDF}$。可以看出，关键字的权重与它在文档中出现的次数成正比，和包含该关键字的文档个数成反比。

一篇文档很可能会包含多个关键字，首先我们要计算每个关键字的 TF-IDF 权重：$w_1, w_2, \ldots, w_n$，然后对这些权重进行归一化处理:

$$w' = w \div \sqrt{w_1^2 + w_2^2 + \cdots + w_n^2}$$

倒排索引中保存是归一化后的权重，即 w'。

2. 第二期：在线部分

2.1 2.1 服务端框架

服务器端框架的选择有两种：① Reactor ② wfrest

我们建议大家使用 Reactor 框架，原因有两点：

1. 可以帮助大家复习前面 Reactor 的知识点。由于 Linux 还没有真正 (内核级别) 的异步 I/O，所以，目前 Linux 平台几乎所有的高性能网络框架都是基于 Reactor 模型和 `epoll` 的。
2. 可以达到更好的锻炼效果。自己从 0 实现一个 WebServer，有助于大家锻炼自己的编码水平，也有助于帮助大家理解网络框架的底层原理。

服务器端整体框架如下所示 (仅供参考)：

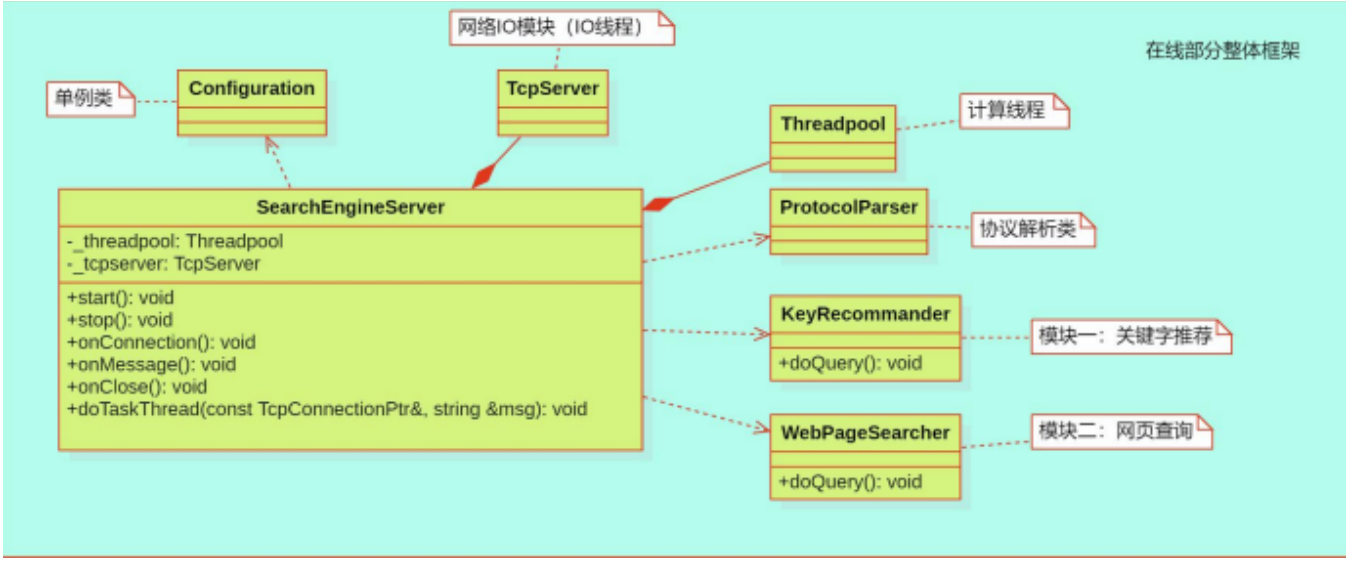

由于 Reactor 是基于 TCP 的。我们需要自定义协议来解决 TCP 的粘包和半包问题，一般我们会采用 TLV 协议：

```
struct Message {
    int tag;    // 消息的类型    1: 关键字推荐 2: 网页搜索
    int length; // value的长度
    std::string value;  //消息的内容
};
```

2.2 2.2 关键字推荐

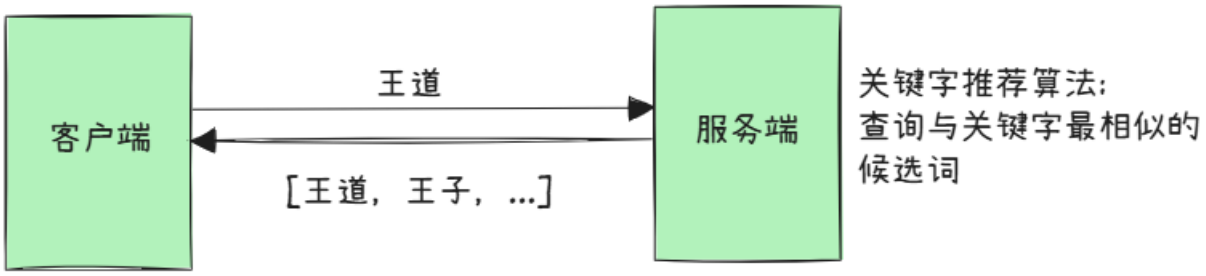

服务器获取客户端传过来的关键字后，会根据 **索引库** 和 **词典库**，选取与关键字最相近的一些候选词，并将其返回给客户端。

候选词的选取

1. 将关键字拆分成一个一个字符。
2. 通过索引库获取每一个字符对应的词语集合，合并所有的词语集合，得到候选词集合。
3. 通过 **编辑距离** 算法，计算候选词集合中的候选词与关键字的相似度。
4. 选择最相近的候选词：
    - 优先比较编辑距离
    - 在编辑距离相同的情况下，比较候选词的词频；优先选择词频高的候选词。
    - 在词频相同的情况下，按字典序比较候选词的大小；优先选择小的候选词。
5. 选择最相近的 k (例如：3 个或 5 个) 个候选词，以 JSON 格式返回给客户端。(提示：可以使用优先队列

`priority_queue`)

2.3 2.3 网页搜索

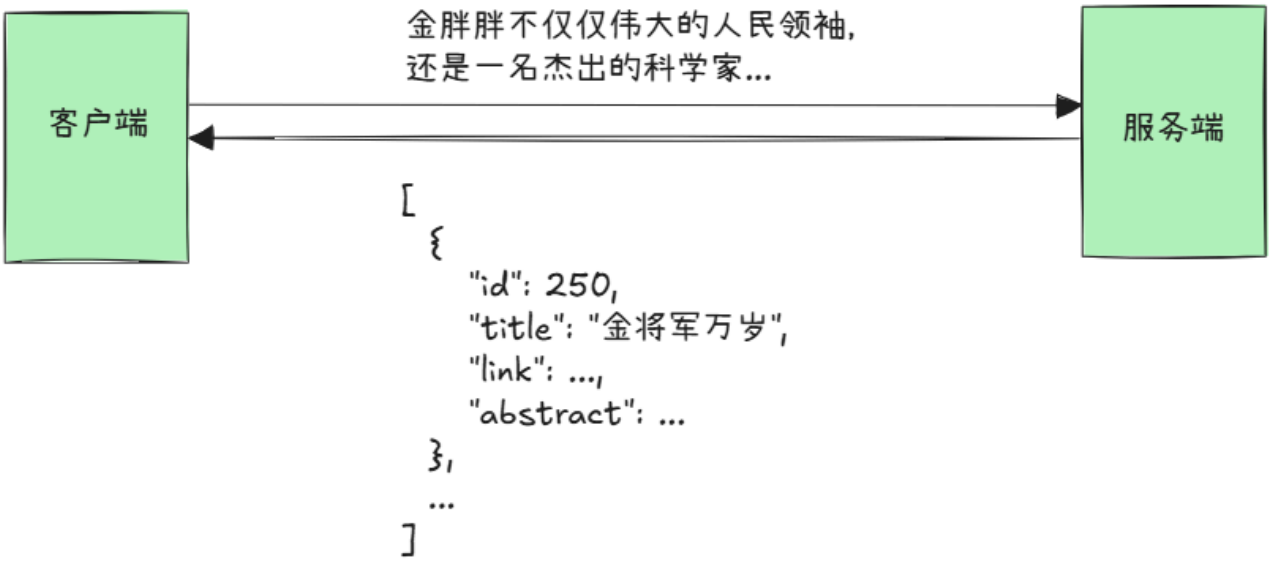

服务器获取客户端输入的查询内容，会根据 **倒排索引库**、**网页库** 和 **网页偏移库** 选取与查询内容最相关的一些网页，并根据网页内容 (< content > 标签中的内容) 生成摘要 (abstract)，返回给客户端。

网页的选取

1. 核心处理：将用户输入的查询内容视为一篇新的 **文档 X**。
    - 使用 cppjieba 对文档 X 进行分词，过滤停用词，获取关键字集合。
    - 使用 TF-IDF 算法计算出每个关键字的权重，将其组成一个向量 $X = (x_1, x_2, \ldots, x_n)$，我们称该向量为 Base (基准向量)。
2. 通过倒排索引库，查询包含所有关键字的网页。当网页库很大的情况下，我们几乎总是可以找到这样的网页的；如果没有包含所有关键字的网页，我们就返回空数组。
3. 如果找到了包含所有关键字的网页，我们则采用 **余弦相似度** 算法对网页进行排序。
    - 既然网页包含所有的关键字，那么我们就可以通过倒排索引库获取每一个关键字的权重，将其组成向量 $Y = (y_1, y_2, \ldots, y_n)$。
    - 计算基准向量 X 与 Y 的余弦值，该余弦值就代表了 X 与 Y 的相似度。
    - 根据余弦值对网页进行排序，余弦值越大越相似，网页也就越靠前。

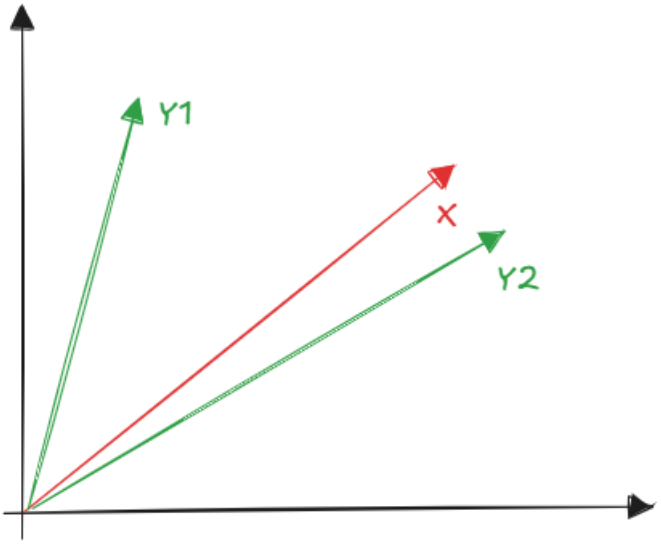

$$cos\theta = \frac{X \cdot Y}{|X||Y|}$$

$$X \cdot Y = x_1y_1 + x_2y_2 + \cdots + x_ny_n$$

4. 找到网页之后，我们需要提取每篇网页中的 id, title, link 信息，并根据网页内容生成摘要 (abstract)。将这些信息封装到 JSON 中，返回给客户端。生成摘要有两种方式：
    - 静态摘要：将文档的内容的前 n 个字符作为摘要，比如前 50 个字符。
    - 动态摘要：将查询关键字附近的文字组成摘要。

3. 第三期：缓存设计

我们可以使用缓存来加快查询结果。在我们这个项目中，缓存有三种设计方案：

- 直接使用 Redis
- 自己设计缓存 (比如 `LRUCache`)
- `LRUCache` 作为一级缓存，Redis 作为二级缓存。(`LRUCache` 在进程内部，速度会比 `Redis` 快一个数量级)

3.1 3.1 LRUCache

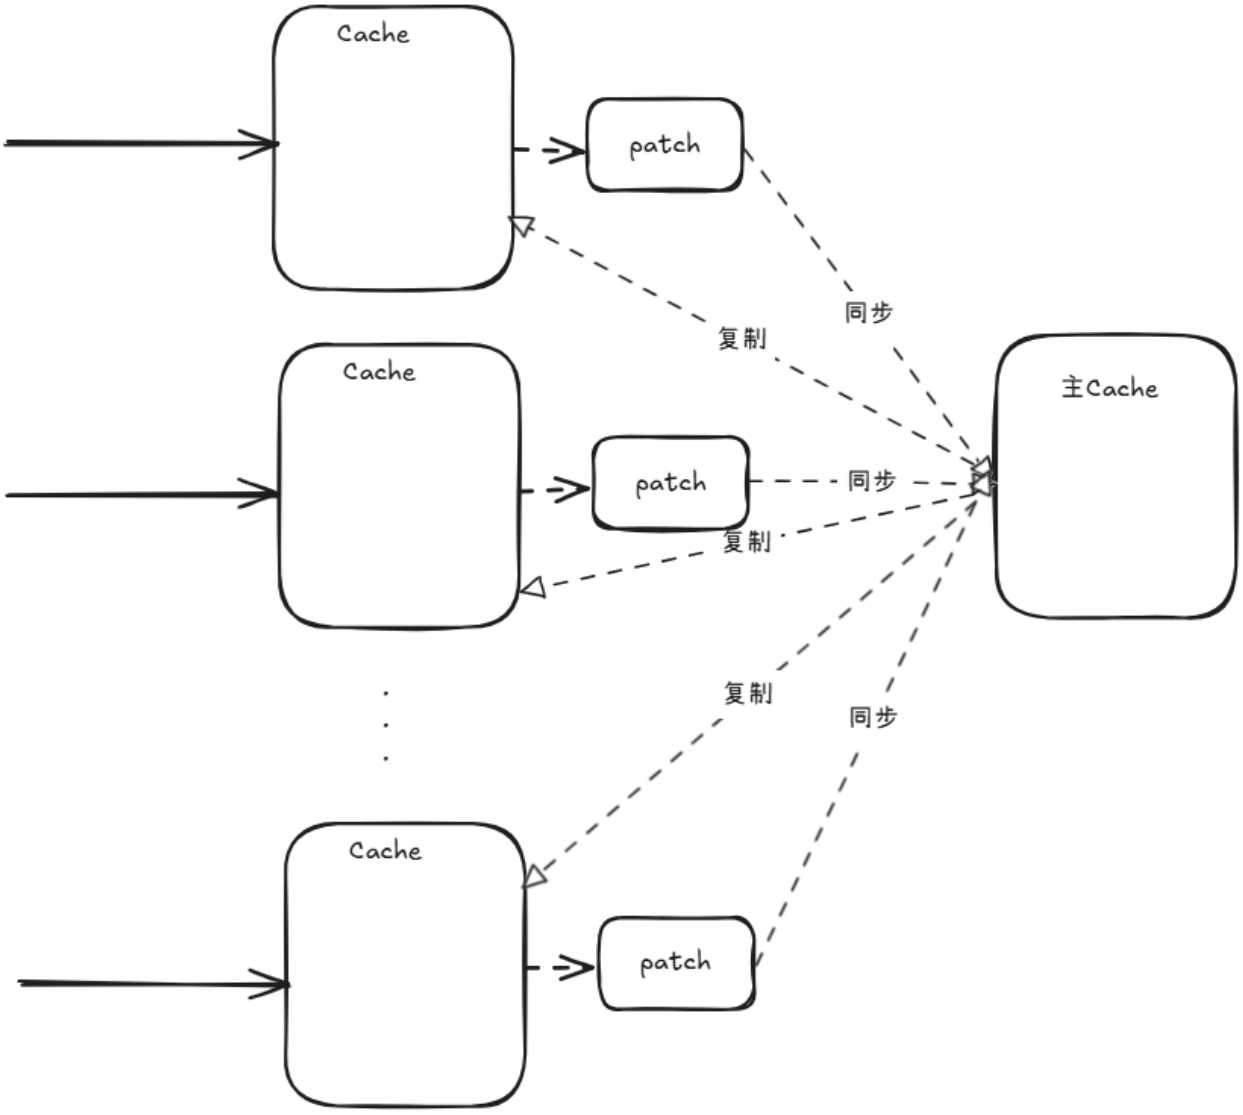

Case 1: 缓存命中

1. 查询 `LRUCache`，命中
2. 将查询结果返回给客户端

Case 2: 缓存未命中

1. 查询 `LRUCache`，未命中
2. 查库 (文件或数据库)，计算结果
3. 将计算结果放入 cache
4. 将计算结果放入 patch

Case 3: 缓存同步 (定时任务)

1. 将各个线程的 patch 添加到主缓存
2. 将主缓存的数据复制到各个线程的 cache

要让每个线程都有自己的 cache 和 patch，我们可以自定义线程结构，如下所示 (仅供参考):

```
struct MyThread
{
    int id;     // 用户自定义的线程 id
    thread* th; // 线程
    LRUCache cache; // LRUCache里面会有互斥锁，同步的时候需要获取该互斥锁
    LRUCache patch;
    ThreadPool* pool;   // 指向线程池，通过该指针可以获取线程池的属性
    ...
};
```